

GSM8K におけるエントロピー適応型自己一貫性サンプリングの分析報告

佐々木 駿・川島 英之
慶應義塾大学 理工学部
sasakishun@keio.jp

1 研究概要

本報告は、自己一貫性サンプリングを実装した CASC-lite を用い、算数ベンチマーク GSM8K に対してサンプル数を最大 $n = 50$ まで拡張した再現実験の結果をまとめたものである。目的は SOTA の主張ではなく、サンプル数の増加が精度・レイテンシ・各種信頼度指標に与える影響を明確にすることである。

2 実験構成

Meta-Llama-3-8B-Instruct (HF Transformers) を用い、temperature=0.7, top-p=0.9 とした。全 8,792 問に対し固定 $n = 50$ の推論を一度行い、得られた 50 本の出力から先頭 n 本のみを切り出して多数決を再計算するポストホック評価を採用した。記録した主な指標はプレフィックスエントロピー、投票マージン、二番手票率、サンプル生成時間である。

3 主な結果

3.1 精度とレイテンシ

表 1 に主要なサンプル数での厳密精度と累積レイテンシを示す。10 サンプルまでは比較的大きな改善が得られるが、20 サンプルを超えると増分は 1-2pt に留まる。

Table 1: ポストホック再集計による精度と累積レイテンシ

サンプル数 n	精度	レイテンシ [s]
1	0.457	0.39
5	0.648	1.97
10	0.735	3.94
20	0.780	7.89
30	0.795	11.83
50	0.810	19.72

3.2 信頼度指標との相関

投票マージンは $r = 0.37$ と最も高い正の相関を示し、二番手票率は負の相関 ($r = -0.16$) を示した。一方、プレフィックスエントロピーは $r = 0.08$ と弱く、単独では難問検出に十分ではない。またサンプル生成時間は $r = -0.10$ であり、長時間を要する問題ほど誤答率が高い傾向が確認できた。

4 考察と今後の課題

サンプル数を増やすほど安定に正解へ収束するが, $n = 50$ でも 13.9% は誤答のままであり, 投票マージンが小さい問題に集中している。今後は

- 投票マージンや二番手票率に基づく動的な打ち切り戦略の設計
- ログ尤度や自己検証プロンプトなど追加指標との統合
- 他データセット (MATH 等) への適用と比較

を行い, コスト対効果の高い制御ポリシーを検討する。

参考文献

References

- [1] CASC-lite プロジェクト資料,
<https://github.com/your-org/casc-lite-entropy-adaptive-sc>
- [2] Cobbe, K. ほか: “GSM8K: A Dataset for Grade School Math Word Problems,”
arXiv:2110.14168, 2021.